
UNIVERSIDADE FEDERAL DE OURO PRETO
DEPARTAMENTO DE CIÊNCIA DE COMPUTAÇÃO
PROCESSAMENTO DIGITAL DE IMAGENS

Projeto de Pesquisa

USO DE CUBOS DE DADOS DE OBSERVAÇÃO DA
TERRA EM ESTUDOS DE DINÂMICA AMBIENTAL NO
BRASIL

Aluno: Gabriel F. Costa

Professor: Guillermo C. Chávez

Sumário

1	Introdução	1
1.1	Objetivos	2
2	Revisão bibliográfica	2
2.1	Cubos de Dados de Satélite	3
2.2	Bandas Espectrais e Reflectância	4
2.3	Séries Temporais de Imagens de Satélite (<i>SITS</i>)	6
2.4	Índices Espectrais	7
2.4.1	Índices de Vegetação	8
2.4.2	Índices de Umidade	9
2.4.3	Índices de Solo Exposto e Nuvem	10
2.4.4	Índice de Queimada	11
3	Materiais e Métodos	11
3.1	Fonte dos Dados	11
3.2	Seleção e Pré-processamento dos Dados	12
3.3	Cálculo dos Índices Espectrais e Processamento	12
3.4	Análise do Impacto das Nuvens	13
3.5	Análise de Séries Temporais dos Índices Espectrais	16
3.6	Contexto das Queimadas em Ouro Preto	16
4	Resultados	18
4.1	Comparação de Séries com e sem Máscara de Nuvem	18
4.2	Decomposição de Séries Temporais e Detecção de Rupturas	20
5	Conclusão	24

Resumo

O presente trabalho investiga o uso de cubos de dados de observação da Terra, com foco no projeto *Brazil Data Cube* (BDC), uma iniciativa do INPE voltada à organização e análise de séries temporais de imagens de satélite. São discutidas as principais aplicações do BDC no mapeamento de uso e cobertura da terra, detecção de distúrbios florestais, monitoramento de queimadas e governança ambiental. A partir disso, o estudo realiza a extração de séries temporais de índices espectrais para a região de Ouro Preto, testando hipóteses relacionadas à dinâmica ambiental local. Os resultados evidenciam que o BDC constitui uma ferramenta avançada para análises espaço-temporais em larga escala, apesar das limitações relacionadas à acurácia, complexidade computacional e necessidade de validações em campo. A combinação entre análise teórica e aplicação prática permite identificar oportunidades de aprimoramento e direcionar futuras pesquisas no contexto da dinâmica ambiental brasileira.

1 Introdução

O avanço das tecnologias de sensoriamento remoto e o crescimento exponencial no volume de dados orbitais impulsionaram o desenvolvimento de novas abordagens para o processamento, análise e extração de informações espaciais e temporais (Santos et al., 2020). Nesse contexto, o projeto *Brazil Data Cube* (BDC), desenvolvido pelo Instituto Nacional de Pesquisas Espaciais (INPE), é uma iniciativa estratégica que visa organizar, processar e disponibilizar séries temporais de imagens de satélite em forma de cubos de dados, otimizados para aplicações em monitoramento ambiental, uso e cobertura da terra, e detecção de mudanças (Brazil Data Cube, 2025).

Produzindo dados harmonizados de média resolução para todo o território nacional, o BDC integra imagens de diferentes sensores com distintas resoluções temporais e espaciais. Sua infraestrutura inclui uma plataforma computacional baseada em inteligência artificial, aprendizado de máquina e análise de séries temporais, apoiando tanto pesquisas científicas quanto políticas públicas ambientais (Simoes et al., 2021). O projeto está inserido no escopo do Monitoramento Ambiental dos Biomas Brasileiros, com apoio do (Fundo Amazônia, 2023), (Banco Nacional de Desenvolvimento Econômico e Social (BNDES), 2023) e (Fundação de Ciência, Aplicações e Tecnologia Espaciais (FUNCATE), 2023).

Entre suas principais aplicações destacam-se o monitoramento do desmatamento, da degradação florestal, da expansão agrícola e das queimadas — temas de grande relevância socioambiental no Brasil camara2023impact, campanharo2023mapeamento, macul2022uso, simoes2021satellite. Os dados fornecidos pelo BDC são pré-processados, padronizados e disponibilizados por meio de uma infraestrutura que facilita a análise de séries temporais e a identificação de padrões espaço-temporais (Brazil Data Cube, 2025).

Neste trabalho, aplicamos a plataforma do BDC para extrair séries temporais de índices especiais na região de Ouro Preto (MG), buscando testar hipóteses relacionadas à dinâmica ambiental local. Essa abordagem, aliada a uma revisão crítica da literatura, permite identificar desafios técnicos e validar empiricamente a aplicabilidade do BDC em estudos ambientais de escala local.

Consideramos, por exemplo, que quedas abruptas nos valores do NDVI ao longo do tempo podem estar associadas à ocorrência de queimadas na região, dado que a vegetação afetada pelo fogo tende a apresentar significativa perda de biomassa (Câmara et al., 2022). Além disso, espera-

se que o índice NDWI apresente comportamento sazonal compatível com os períodos de chuva e estiagem típicos da região, refletindo as variações na umidade da vegetação e do solo (Gao, 1996).

1.1 Objetivos

O objetivo geral deste trabalho é investigar os padrões espaço-temporais de índices espectrais relacionados à vegetação, umidade, exposição do solo e detecção de nuvens na região de Ouro Preto (MG), utilizando dados do *Brazil Data Cube* (BDC). Este estudo busca compreender como esses índices podem auxiliar na identificação de eventos ambientais relevantes, como queimadas, estiagens e mudanças na cobertura do solo.

Para isso, foram definidos os seguintes objetivos específicos:

- Extrair séries temporais de índices espectrais, tais como NDVI, NDWI, MNDWI, BSI, CDI e outros para a área de estudo, a partir dos cubos de dados do BDC.
- Avaliar a variação temporal desses índices e analisar sua relação com eventos ambientais observados, especialmente queimadas.
- Investigar o impacto da aplicação de máscaras de nuvem na qualidade das séries temporais geradas.
- Verificar se os padrões sazonais dos índices de umidade coincidem com os períodos de estiagem conhecidos para a região de Ouro Preto.

2 Revisão bibliográfica

Esta seção apresenta os fundamentos teóricos e os avanços recentes relacionados ao *Brazil Data Cube* (BDC) e às tecnologias envolvidas em sua construção e aplicação. O objetivo é oferecer uma base conceitual sólida para compreender os dados, métodos e análises que sustentam esta pesquisa, com ênfase em sensoriamento remoto, séries temporais e índices espectrais.

Recentemente, métodos de **deep learning** têm sido aplicados no processamento de séries temporais de imagens de satélite, permitindo avanços na classificação, detecção de mudanças e mapeamento de queimadas (Li et al., 2020; X. X. Zhu et al., 2019). Além disso, o monitoramento de

impactos de secas em vegetação utilizando séries temporais tem se consolidado como ferramenta fundamental para a gestão ambiental (Silva et al., 2021). No contexto de distúrbios florestais e degradação ambiental, técnicas de geração e análise de séries temporais sintéticas também vêm sendo empregadas, otimizando a detecção de rupturas e variações sazonais em dados de satélite (Z. Zhu et al., 2020).

2.1 Cubos de Dados de Satélite

Cubos de dados de satélite são estruturas tridimensionais organizadas em latitude, longitude e tempo, otimizadas para o armazenamento e análise de séries temporais consistentes (Câmara et al., 2022). No contexto do BDC, essas estruturas são geradas a partir de imagens harmonizadas de sensores como Landsat e Sentinel-2, que passam por correções atmosféricas e padronizações radiométricas. Essa padronização favorece o uso de técnicas de aprendizado de máquina e estatística em grande escala, permitindo análises espaço-temporais contínuas e automatizadas.

Matematicamente, um cubo de dados pode ser representado como mostrado na Equação 1:

$$\mathcal{C} \in \mathbb{R}^{H \times W \times T}, \quad (1)$$

onde H e W representam, respectivamente, a altura (número de linhas) e a largura (número de colunas) da imagem espacial, e T é o número de imagens (ou cenas) adquiridas ao longo do tempo. Cada elemento $\mathcal{C}_{i,j,t}$ representa o valor de reflectância (ou valor digital) do pixel localizado na posição espacial (i, j) no instante temporal t .

Caso o cubo inclua múltiplas bandas espectrais, a notação é estendida conforme a Equação 2:

$$\mathcal{C} \in \mathbb{R}^{H \times W \times B \times T}, \quad (2)$$

onde B corresponde ao número de bandas espectrais capturadas. Nesse caso, cada elemento $\mathcal{C}_{i,j,b,t}$ representa o valor registrado por uma banda espectral b em uma localização espacial (i, j) e instante temporal t .

Cada unidade elementar dentro desse cubo — definida por uma posição espacial, uma banda espectral e um instante de tempo — é denominada **voxel** (do inglês, *volume element*). Assim como um pixel representa uma unidade em uma imagem bidimensional, um voxel representa um

ponto no espaço-tempo-espectral, sendo a menor unidade indivisível de informação em um cubo de dados multiespectral e temporal (Câmara et al., 2022).

A Figura 1 apresenta uma visão conceitual da estrutura dos cubos de dados do *Brazil Data Cube* (BDC), destacando o empilhamento espaço-temporal de imagens multiespectrais, a organização espacial em regiões geográficas (*tiles*) e o fluxo de processamento, desde a aquisição das imagens até sua disponibilização para análise. A figura também ilustra as etapas de seleção de séries temporais por pixel e de imagens específicas ao longo do tempo, facilitando a análise espaço-temporal de fenômenos observados por sensoriamento remoto.

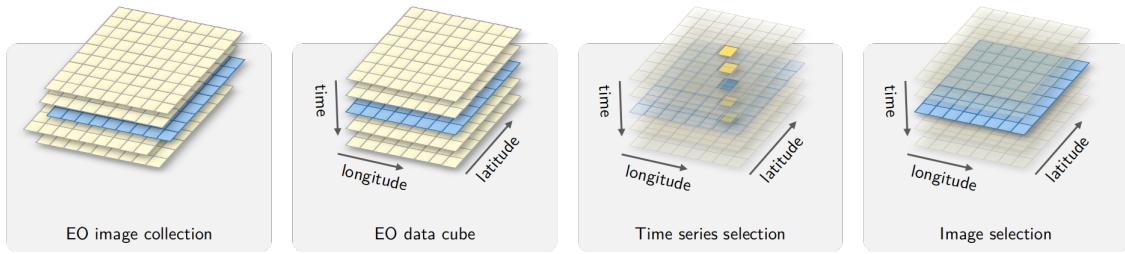


Figura 1: Representação conceitual da estrutura dos cubos de dados do BDC, evidenciando o empilhamento espaço-temporal de imagens multiespectrais, a organização espacial por regiões geográficas (*tiles*) e o fluxo de processamento, desde a coleta das imagens até sua disponibilização para análise. A figura também ilustra as etapas de seleção de séries temporais por pixel e de imagens específicas no tempo, conforme a demanda das aplicações. Fonte: (Câmara et al., 2022).

2.2 Bandas Espectrais e Reflectância

As imagens utilizadas no BDC são compostas por **bandas espectrais** que capturam a **reflectância da superfície terrestre** em diferentes **comprimentos de onda** (Brazil Data Cube, 2025). A reflectância espectral, denotada por $\rho(\lambda)$, é definida como a razão entre a radiação eletromagnética refletida por uma superfície ($L_r(\lambda)$) e a radiação incidente sobre ela ($L_i(\lambda)$) em um dado comprimento de onda λ :

$$\rho(\lambda) = \frac{L_r(\lambda)}{L_i(\lambda)}. \quad (3)$$

A reflectância é uma grandeza adimensional, com valores normalizados entre 0 e 1, onde 0 indica absorção total da radiação e 1 indica reflexão total. Essa medida é fundamental na análise de superfícies terrestres, pois diferentes materiais (água, solo, vegetação, construções) refletem a

radiação de maneira distinta em diferentes bandas do espectro eletromagnético, como ilustrado na Figura 2.

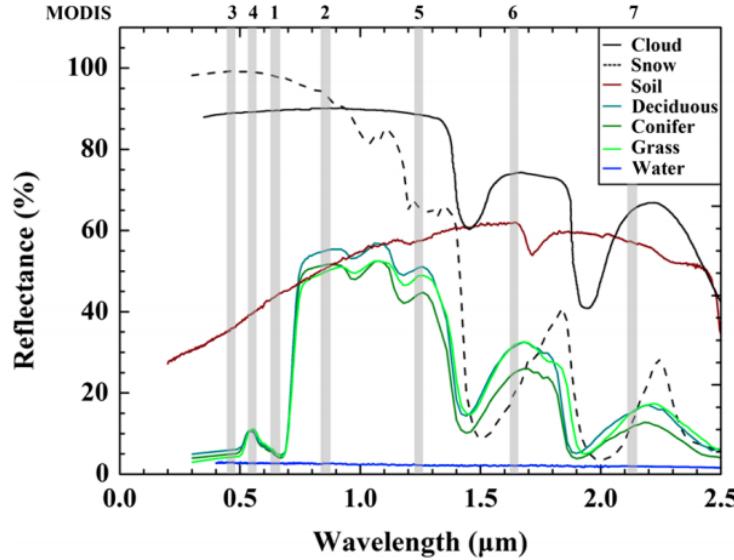


Figura 2: Perfil espectral de diferentes alvos na superfície terrestre. Fonte: (Gonzalez & Woods, 2006).

A Tabela 1 apresenta as principais bandas espetrais utilizadas no BDC, juntamente com os sensores correspondentes e suas aplicações mais comuns nas análises ambientais e de uso da terra.

Tabela 1: Bandas espetrais utilizadas no BDC e suas aplicações.

Banda	Sensor / Descrição	Aplicação
B1	Coastal/Aerosol (Landsat-8/9)	Correções atmosféricas; análise costeira.
B2	Azul (Blue)	Detecção de corpos d'água, nuvens; composição RGB.
B3	Verde (Green)	Estimativa do vigor da vegetação; análise visual.
B4	Vermelho (Red)	Estresse vegetal; diferenciação entre solo e vegetação.
B5 / B8	NIR (Landsat / Sentinel-2)	Base para NDVI, EVI, SAVI.
B6 / B11	SWIR1	Umidade do solo e vegetação.
B7 / B12	SWIR2	Detecção de queimadas, secas e análise geológica.
B8A	NIR refinado (Sentinel-2)	Refinamento de índices espetrais.
B9	Vapor d'água	Correções atmosféricas.
B10 / Cirrus	Térmica / Cirrus	Detecção de nuvens altas e finas.
BQA / QA60	Bandas de qualidade	Mascaramento de nuvens, sombras e neve.

Essas bandas fundamentam o cálculo de índices espectrais amplamente utilizados na análise da vegetação, da umidade do solo e na detecção de distúrbios ambientais, como queimadas e alterações antrópicas.

2.3 Séries Temporais de Imagens de Satélite (**SITS**)

Séries temporais são sequências de observações ordenadas no tempo, representadas por uma função X_t , onde $t \in \{1, 2, \dots, T\}$ indica o tempo. Elas são utilizadas para analisar padrões como tendência (T_t), que se referem a variações de longo prazo; sazonalidade (S_t), que envolve padrões cíclicos; e ruído (e_t), que são flutuações aleatórias (Nielsen, 2019).

A decomposição clássica de uma série temporal aditiva é dada pela equação:

$$X_t = T_t + S_t + e_t. \quad (4)$$

Séries temporais de imagens estendem esse conceito ao domínio espaço-temporal. Para cada pixel (x, y) de uma imagem georreferenciada, observa-se uma sequência de valores ao longo do tempo, representada pela função:

$$R_t = R(\lambda, x, y, t), \quad (5)$$

onde R é a reflectância em um comprimento de onda λ , e t representa a data de aquisição da imagem (Câmara et al., 2022).

A análise dessas séries permite detectar **mudanças ambientais**, como desmatamento, crescimento urbano e sazonalidade agrícola. Métodos como **BFAST** (*Breaks For Additive Season and Trend*) (Verbesselt et al., 2010) identificam pontos de ruptura nas séries temporais. A equação de decomposição continua sendo:

$$R_t = T_t + S_t + e_t. \quad (6)$$

Além disso, técnicas de aprendizado de máquina, como Random Forest, XGBoost e SOM, podem ser aplicadas à série $\{R_t\}$ ou a índices derivados, como NDVI e EVI, para classificar tipos de cobertura do solo ou detectar eventos anômalos.

A Figura 3 ilustra o processo de construção de séries temporais a partir de cubos de dados de observação da Terra e sua aplicação em classificação de uso e cobertura da terra.

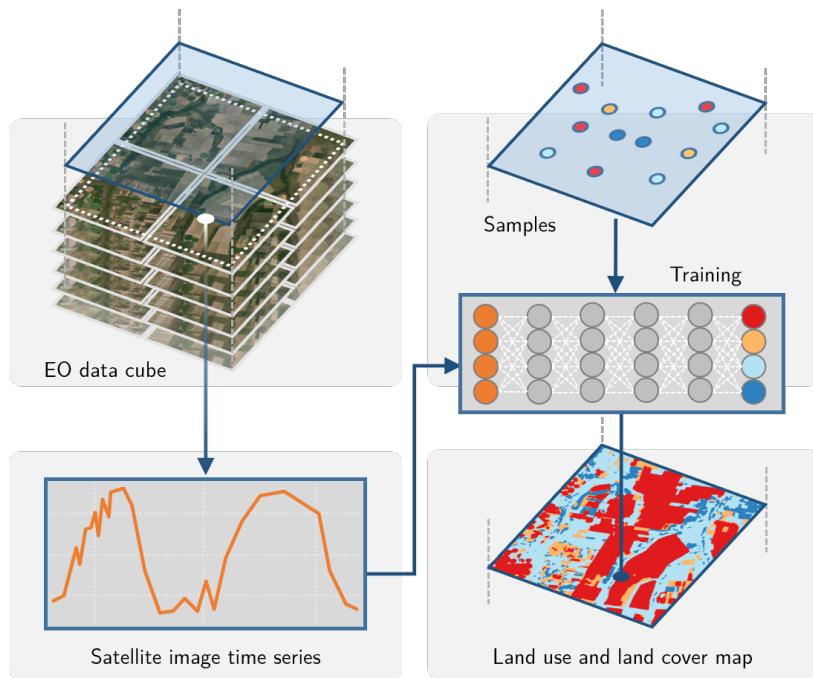


Figura 3: Fluxo de processamento de séries temporais de imagens de satélite: a partir de cubos de dados multidimensionais, extrai-se o perfil temporal dos pixels, que pode ser usado em algoritmos de aprendizado de máquina para gerar mapas de uso e cobertura da terra por exemplo. Fonte: ([Simoes et al., 2021](#)).

2.4 Índices Espectrais

Índices espectrais são combinações algébricas entre bandas espectrais de sensores remotos, formuladas para realçar propriedades biofísicas específicas da superfície terrestre. Essas métricas são amplamente utilizadas no monitoramento da vegetação, corpos d’água, umidade do solo e detecção de mudanças ambientais, sendo fundamentais para análises multitemporais e classificação temática em estudos de sensoriamento remoto ([Câmara et al., 2022](#)).

Os índices podem ser organizados conforme suas principais aplicações: vegetação, umidade, superfícies expostas, identificação de nuvens e caracterização de áreas queimadas.

2.4.1 Índices de Vegetação

Os índices de vegetação aproveitam a característica espectral da vegetação, que reflete intensamente no infravermelho próximo (NIR) e absorve fortemente no vermelho, para inferir propriedades biofísicas relevantes como biomassa, vigor, estresse, teor de clorofila e cobertura foliar (Câmara et al., 2022).

NDVI (Normalized Difference Vegetation Index) (Rouse et al., 1974):

$$\text{NDVI} = \frac{\rho_{\text{NIR}} - \rho_{\text{Red}}}{\rho_{\text{NIR}} + \rho_{\text{Red}}}. \quad (7)$$

Índice clássico e amplamente utilizado para estimar densidade de vegetação. Dado pela Equação 7, valores próximos de 1 indicam vegetação densa e vigorosa; próximos de 0, solos nus ou áreas urbanas; valores negativos sugerem água ou nuvens. Pode saturar em florestas muito densas. Intervalo típico: $[-1, 1]$.

EVI (Enhanced Vegetation Index) (A. Huete et al., 2002):

$$\text{EVI} = 2.5 \cdot \frac{\rho_{\text{NIR}} - \rho_{\text{Red}}}{\rho_{\text{NIR}} + 6\rho_{\text{Red}} - 7.5\rho_{\text{Blue}} + 1}. \quad (8)$$

Dado pela Equação 8, o EVI foi projetado para lidar com a saturação do NDVI e corrigir efeitos atmosféricos e de solo. Inclui a banda azul para minimizar o espalhamento. Ideal para vegetação densa, como florestas tropicais. Intervalo típico: $[-2, 2]$.

SAVI (Soil Adjusted Vegetation Index) (A. R. Huete, 1988):

$$\text{SAVI} = \frac{(1+L)(\rho_{\text{NIR}} - \rho_{\text{Red}})}{\rho_{\text{NIR}} + \rho_{\text{Red}} + L}, \quad L = 0.5. \quad (9)$$

Dado pela Equação 9, o SAVI corrige a influência do solo em ambientes com vegetação esparsa. É útil para monitoramento agrícola em áreas com solo exposto. Intervalo típico: $[-1, 1]$.

MSAVI (Modified SAVI) (Qi et al., 1994):

$$\text{MSAVI} = \frac{2\rho_{\text{NIR}} + 1 - \sqrt{(2\rho_{\text{NIR}} + 1)^2 - 8(\rho_{\text{NIR}} - \rho_{\text{Red}})}}{2}. \quad (10)$$

Dado pela Equação 10, o MSAVI é uma variação do SAVI com ajuste automático do parâmetro

L , o que melhora a sensibilidade em áreas com vegetação muito rala. Intervalo típico: $[-1, 1]$.

ARVI (Atmospherically Resistant Vegetation Index) (Kaufman & Tanre, 1992):

$$\text{ARVI} = \frac{\rho_{\text{NIR}} - \rho_{\text{Red}}}{\rho_{\text{NIR}} + \rho_{\text{Red}} - 2\rho_{\text{Blue}}}. \quad (11)$$

Dado pela Equação 11, esse índice utiliza a banda azul para compensar a dispersão atmosférica, sendo indicado para ambientes com poeira, fumaça ou poluição. Intervalo típico: $[-1, 1]$.

GNDVI (Green NDVI) (Gitelson & Merzlyak, 1996):

$$\text{GNDVI} = \frac{\rho_{\text{NIR}} - \rho_{\text{Green}}}{\rho_{\text{NIR}} + \rho_{\text{Green}}}. \quad (12)$$

Dado pela Equação 12, o GNDVI substitui o vermelho pelo verde, o que aumenta a sensibilidade ao teor de clorofila. É eficaz para detecção precoce de estresse em cultivos. Intervalo típico: $[-1, 1]$.

NDRE (Normalized Difference Red Edge) (Gitelson et al., 2001):

$$\text{NDRE} = \frac{\rho_{\text{NIR}} - \rho_{\text{RedEdge}}}{\rho_{\text{NIR}} + \rho_{\text{RedEdge}}}. \quad (13)$$

Dado pela Equação 13, o NDRE utiliza a banda da borda do vermelho, sensível a variações sutis na saúde da vegetação. É útil para estimativas de nitrogênio e vigor em fases iniciais do ciclo agrícola. Intervalo típico: $[-1, 1]$.

2.4.2 Índices de Umidade

Esses índices são construídos para realçar variações na reflectância em bandas sensíveis à presença de água, como o SWIR. Ajudam a identificar corpos hídricos, umidade do solo e estresse hídrico na vegetação.

NDWI (Normalized Difference Water Index) (Gao, 1996):

$$\text{NDWI} = \frac{\rho_{\text{NIR}} - \rho_{\text{SWIR}}}{\rho_{\text{NIR}} + \rho_{\text{SWIR}}}. \quad (14)$$

Dado pela Equação 14, o NDWI é sensível à umidade da vegetação. Reduções nos seus valores

podem indicar estresse hídrico, seca ou perda de biomassa. É comumente usado para monitoramento agrícola e avaliação da saúde das culturas. Intervalo típico: $[-1, 1]$.

MNDWI (Modified NDWI) ([Xu, 2006](#)):

$$MNDWI = \frac{\rho_{Green} - \rho_{SWIR}}{\rho_{Green} + \rho_{SWIR}}. \quad (15)$$

Dado pela Equação 15, esse índice melhora a detecção de corpos d'água ao suprimir ruídos causados por construções, solo exposto e vegetação. É amplamente utilizado em monitoramento de inundações, mapeamento de lagos e reservatórios. Intervalo típico: $[-1, 1]$.

NDMI (Normalized Difference Moisture Index) ([Wilson & Sader, 2002](#)):

$$NDMI = \frac{\rho_{NIR} - \rho_{SWIR_1}}{\rho_{NIR} + \rho_{SWIR_1}}. \quad (16)$$

Dado pela Equação 16, o NDMI busca identificar mudanças na umidade da vegetação, sendo sensível à perda de água nas folhas. É eficaz para prever o risco de incêndios florestais e avaliar o estresse hídrico em florestas e áreas agrícolas. Intervalo típico: $[-1, 1]$.

2.4.3 Índices de Solo Exposto e Nuvem

Esses índices foram projetados para detectar áreas com pouca ou nenhuma vegetação, como solos nus, superfícies artificiais e a presença de nuvens.

BSI (Bare Soil Index) ([Rikimaru & Miyatake, 2002](#)):

$$BSI = \frac{(\rho_{Blue} + \rho_{Red}) - (\rho_{NIR} + \rho_{SWIR_1})}{(\rho_{Blue} + \rho_{Red}) + (\rho_{NIR} + \rho_{SWIR_1})}. \quad (17)$$

Dado pela Equação 17, o BSI foi desenvolvido para realçar áreas de solo exposto, com valores altos indicando baixa cobertura vegetal. É útil em análises de degradação ambiental, desertificação e planejamento urbano. Intervalo típico: $[-1, 1]$.

CDI (Cloud Discrimination Index) ([Z. Zhu & Woodcock, 2012](#)):

$$CDI = \frac{\rho_{SWIR} - \rho_{Blue}}{\rho_{SWIR} + \rho_{Blue}}. \quad (18)$$

Dado pela Equação 18, o CDI diferencia nuvens de superfícies claras como neve ou areia. Baixos valores estão associados à presença de nuvens. É comumente usado como máscara auxiliar em etapas de pré-processamento de séries temporais. Intervalo típico: $[-1, 1]$.

2.4.4 Índice de Queimada

NBR (Normalized Burn Ratio) (Key & Benson, 2006):

$$\text{NBR} = \frac{\rho_{\text{NIR}} - \rho_{\text{SWIR}}}{\rho_{\text{NIR}} + \rho_{\text{SWIR}}}.$$
 (19)

Dado pela Equação 19, o NBR explora o contraste entre a alta refletância da vegetação no NIR e sua forte absorção no SWIR para detectar áreas queimadas. Após um incêndio, o NBR tende a diminuir significativamente. É essencial para estimar áreas afetadas por fogo e calcular a severidade da queimada. Intervalo típico: $[0, 1]$.

3 Materiais e Métodos

Esta seção descreve os dados e os procedimentos utilizados para análise temporal dos índices espectrais, incluindo a origem das imagens, extração dos índices e a detecção de rupturas nas séries temporais.

3.1 Fonte dos Dados

Os dados utilizados neste estudo foram obtidos a partir do *Brazil Data Cube* (BDC). Para este trabalho, foram utilizados dados do satélite Sentinel-2, que possui resolução espacial entre 10 e 60 metros, dependendo da banda, e resolução temporal aproximada de 16 dias devido ao ciclo de revisitamento da constelação. O Sentinel-2 disponibiliza 13 bandas espectrais, abrangendo desde o espectro visível até o infravermelho de ondas curtas.

3.2 Seleção e Pré-processamento dos Dados

A seleção dos dados foi realizada via consulta à API STAC (*Brazil Data Cube - Spatiotemporal Asset Catalog (STAC)*, 2023) do BDC, definindo-se a área de interesse por meio de uma caixa delimitadora geográfica (*bounding box*) correspondente à região de Ouro Preto (MG) e um intervalo temporal de 1º de janeiro de 2019 até julho de 2025. A busca retornou 148 itens que contêm as bandas espectrais necessárias para o cálculo dos índices.

A caixa delimitadora utilizada nos experimentos foi definida pelas seguintes coordenadas geográficas (graus decimais, WGS84):

$$\left\{ \begin{array}{l} \text{Longitude Oeste (min)} = -43.5411633. \\ \text{Latitude Sul (min)} = -20.4293283. \\ \text{Longitude Leste (max)} = -43.4655633. \\ \text{Latitude Norte (max)} = -20.3553283. \end{array} \right.$$

As bandas espectrais foram carregadas diretamente dos arquivos *raster* correspondentes, utilizando a biblioteca `rasterio`, com leituras espacialmente limitadas à área de estudo e reprojeção quando necessária.

A Figura 4 apresenta uma composição visual das bandas espectrais extraídas para a região de interesse em um dos dias dentro do intervalo analisado, destacando a extensão espacial coberta pelos dados utilizados. A Figura 5, por sua vez, exibe os histogramas das distribuições dessas bandas para o mesmo dia de análise da figura anterior, permitindo avaliar a distribuição espectral dos valores observados e contribuindo para a compreensão das características ambientais registradas nessa data.

3.3 Cálculo dos Índices Espectrais e Processamento

Foram computados índices espectrais relevantes para análise da vegetação, exposição do solo e umidade, calculados pixel a pixel a partir das bandas normalizadas, conforme as fórmulas padronizadas de cada índice.

Para otimizar o processamento, a computação dos índices para todos os itens foi paralelizada

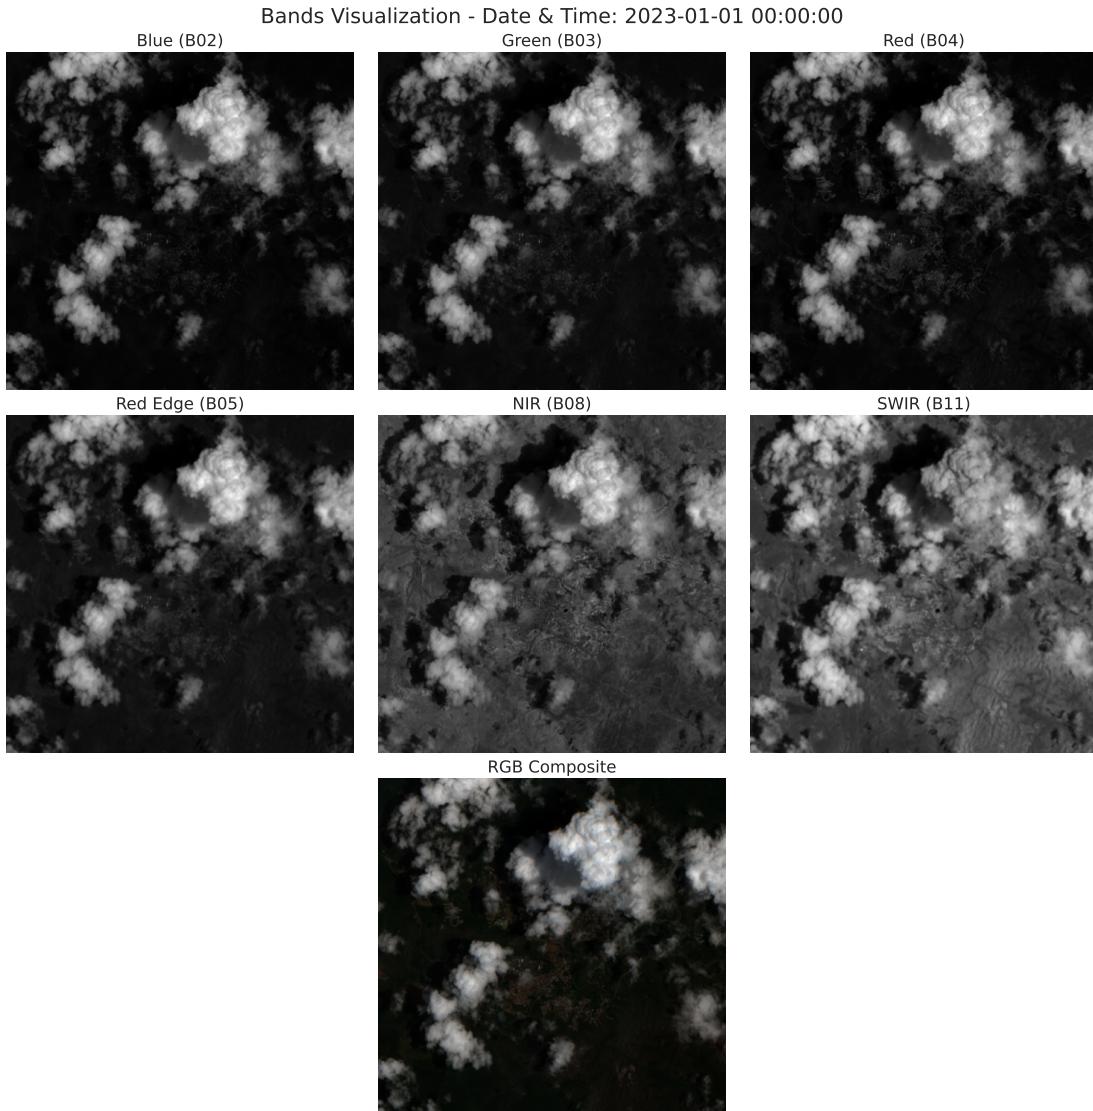


Figura 4: Composição visual das bandas espectrais de um único dia extraídas para a região de Ouro Preto (MG), com destaque para a delimitação espacial usada na análise. Fonte: Elaborado pelo autor.

utilizando a biblioteca `multiprocessing` do Python, explorando múltiplos núcleos de processamento.

3.4 Análise do Impacto das Nuvens

Visando avaliar o impacto da presença de nuvens nas séries temporais, realizou-se um experimento comparativo utilizando máscara de nuvens construída a partir do índice CDI. Pixels com valores de CDI abaixo de um limiar (*threshold*) foram considerados contaminados por nuvens e

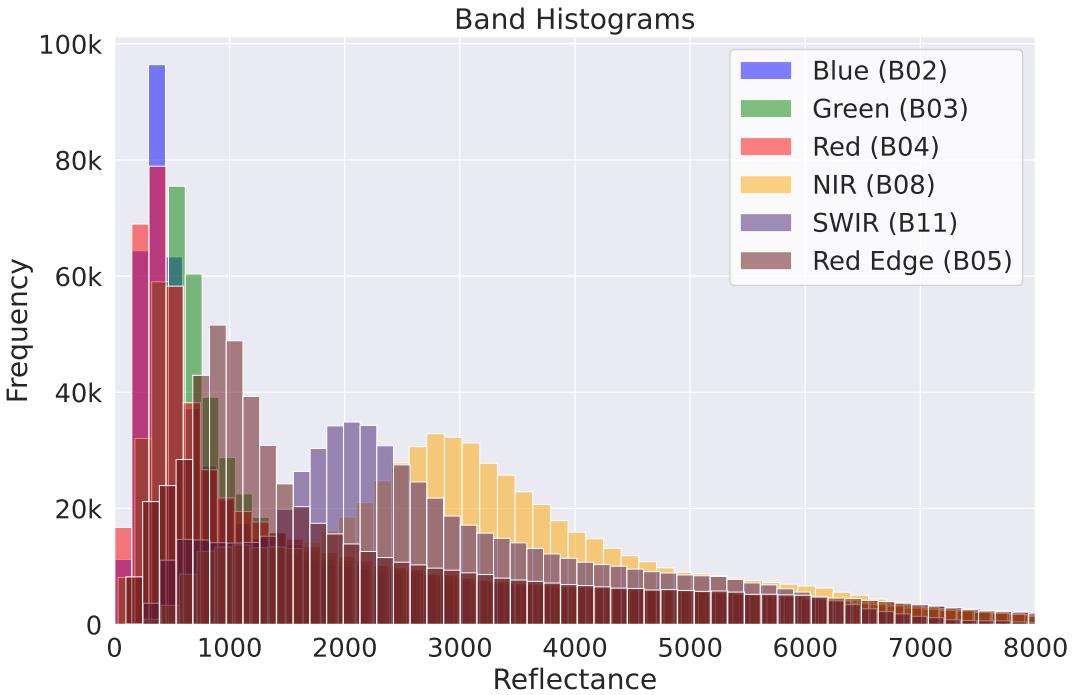


Figura 5: Histogramas das distribuições das bandas espectrais para o mesmo dia de 4. Fonte: Elaborado pelo autor.

removidos nas séries espectrais.

As séries médias com e sem máscara foram comparadas por métricas quantitativas como correlação de Pearson (r), erro absoluto médio (MAE) e diferença absoluta máxima (Nielsen, 2019), definidas respectivamente por:

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}, \quad (20)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |X_i - Y_i|, \quad (21)$$

$$\max_{i=1,\dots,n} |X_i - Y_i|, \quad (22)$$

onde X e Y representam as séries temporais com e sem aplicação da máscara, respectivamente, e n o número de observações.

Esta análise permitiu quantificar o efeito das nuvens nos índices espectrais e avaliar a robustez

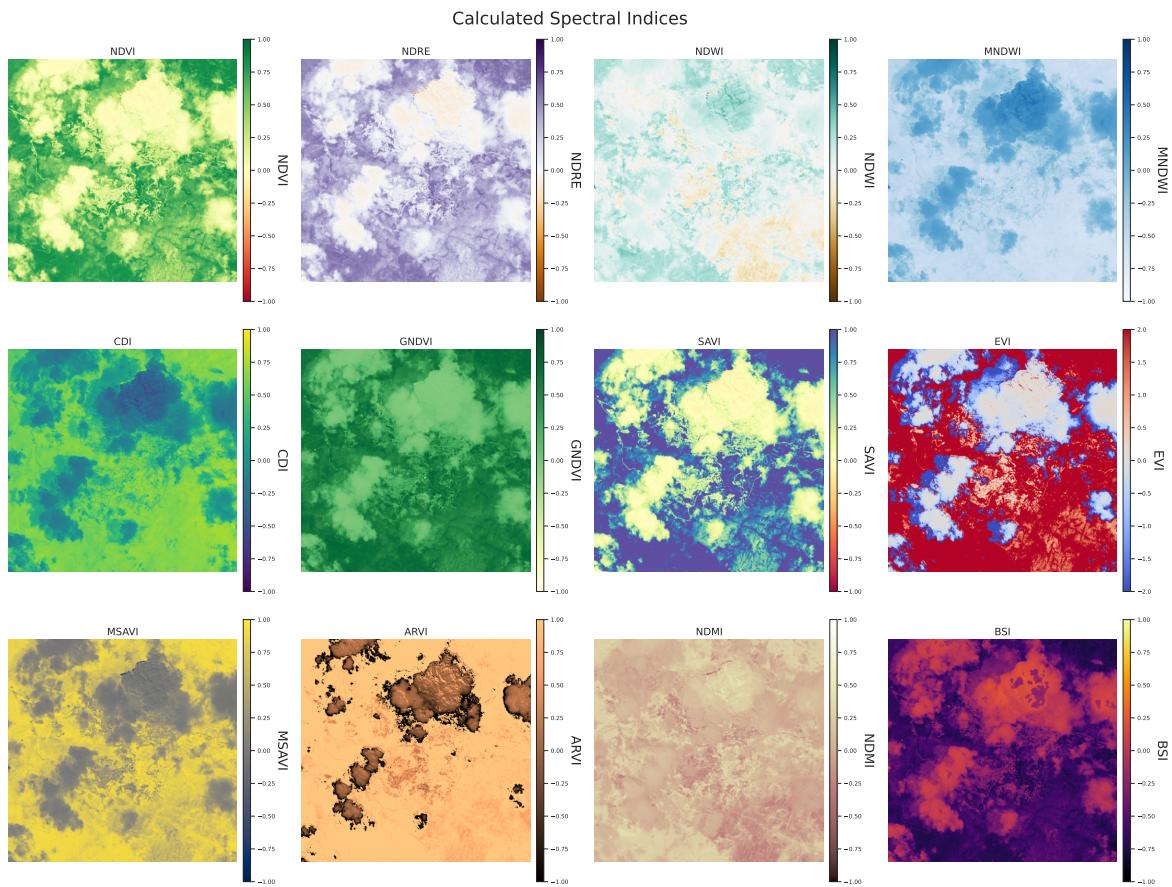


Figura 6: Índices espectrais (NDVI, NDMI, BSI, CDI, entre outros) para a mesma data ilustrada nas Figuras 4 e 5. A análise comparativa desses índices permite uma visão integrada das condições de vegetação, umidade e exposição do solo no dia selecionado.

dos mesmos frente a este ruído atmosférico.

3.5 Análise de Séries Temporais dos Índices Espectrais

Nesta etapa, realizamos uma análise detalhada das séries temporais dos índices espectrais NDVI, NDMI e NBR. O objetivo é decompor essas séries em componentes de tendência, sazonalidade e ruído, possibilitando uma compreensão mais clara dos padrões temporais subjacentes.

A decomposição foi realizada por meio do modelo aditivo, assumindo um período de 23 observações, o que corresponde ao intervalo médio de aquisição das imagens Sentinel-2 com composição a cada 16 dias. Essa abordagem permite distinguir variações sazonais recorrentes de tendências de longo prazo e componentes residuais associadas a ruídos ou flutuações não explicadas.

Além da decomposição, aplicamos técnicas de detecção de rupturas estruturais (*change point detection*) com o algoritmo PELT (*Pruned Exact Linear Time*) (Killick et al., 2012). Esse algoritmo é reconhecido por sua eficiência na identificação exata de múltiplos pontos de mudança, com complexidade linear em muitos casos. Diferentemente de abordagens mais simples, o mesmo optimiza uma função de custo penalizada, considerando a melhor segmentação da série com base na minimização de erros internos aos segmentos.

Nesta implementação, empregamos o modelo `rbf` (*Radial Basis Function*) como função de custo, o qual é mais sensível a mudanças graduais e padrões não lineares na série temporal do que modelos clássicos como o erro quadrático (L_2). O uso deste permite detectar mudanças sutis no comportamento da série — como transições progressivas de vegetação ou umidade — que poderiam passar despercebidas com modelos baseados apenas na média.

Os resultados obtidos revelam a capacidade combinada da decomposição sazonal e da detecção de rupturas em capturar variações estruturais e padrões sazonais nos índices espectrais. Embora tenhamos concentrado a análise em NDVI, NDMI e NBR nesta fase, a metodologia é aplicável a outros índices e pode ser expandida em etapas subsequentes do estudo.

3.6 Contexto das Queimadas em Ouro Preto

Durante a segunda metade de 2024, a região de Ouro Preto (MG) enfrentou uma sucessão de focos de incêndios florestais, com impactos significativos no Parque Estadual do Itacolomi, no

Morro da Queimada e áreas rurais e urbanas adjacentes. O dia 22 de agosto marcou o registro de um incêndio de grandes proporções no Parque do Itacolomi, ameaçando a vegetação local e causando intensa fumaça sobre a cidade histórica ([G1 Minas Gerais, 2024](#)). Nos dias seguintes, em 29 de agosto, foram observadas queimadas espalhadas por Mariana e Ouro Preto, que escureceram o céu local e causaram situação de incômodo à população [jornalpfqueimadas2024, diariooopc.inza2024](#).



Figura 7: Incêndio consome parte do Parque Estadual do Itacolomi em agosto de 2024. Fonte: ([de Godoy, 2025](#)).

Relatos da presença de fauna silvestre — como a aparição de um lobo-guará no Morro da Queimada em 5 de setembro, exibindo sinais de deslocamento possivelmente provocado pelos incêndios — evidenciam a dimensão dos impactos ambientais e ecológicos desses eventos ([Radar Geral, 2024](#)).

Dados do Instituto Nacional de Pesquisas Espaciais (INPE) apontam que, em Minas Gerais, as ocorrências de queimadas em agosto de 2024 aumentaram cerca de 80% em relação a julho, representando uma crise ambiental que refletiu diretamente no entorno urbano de Ouro Preto e na região dos Inconfidentes ([Gazeta de Varginha, 2024](#)).

Curiosamente, o contexto climático contribuiu para a mitigação dos danos causados pelos incêndios: o início da estação chuvosa na segunda metade de 2024 trouxe chuvas regulares que favoreceram a recuperação da vegetação nos meses finais do ano. Essa dinâmica — agravamento por eventos extremos seguido de regeneração ambiental — deve ser considerada na interpretação das rupturas observadas nas séries temporais dos índices espectrais.

4 Resultados

Esta seção apresenta os principais resultados da análise temporal dos índices espectrais para a região de Ouro Preto (MG), entre 2019 e 2025. São abordadas duas frentes: (i) a avaliação do impacto da aplicação de máscaras de nuvem sobre a consistência das séries temporais e (ii) a decomposição dos índices NDVI, NDMI e NBR com a tentativa de identificação de rupturas nas séries.

4.1 Comparação de Séries com e sem Máscara de Nuvem

As Figuras 8 e 9 mostram a comparação entre as séries temporais médias dos índices espectrais com e sem a aplicação de máscara de nuvem. As curvas exibem similaridades visuais significativas, o que já sugere baixa interferência média das nuvens nos valores regionais agregados.

Contudo, uma inspeção mais atenta nas Figuras 8–9 mostra que alguns índices (como EVI e ARVI) apresentam oscilações abruptas na série sem máscara, possivelmente atribuídas a artefatos atmosféricos. A máscara suaviza esses desvios, ainda que o impacto agregado seja pequeno, como indicam os altos coeficientes de correlação e baixos erros absolutos apresentados na Tabela 2. A exceção é o índice EVI, que apresentou maior sensibilidade, possivelmente por sua maior dependência da banda azul.

Tabela 2: Métricas de desempenho para os índices espectrais, comparando séries com e sem máscara de nuvem.

Índice	Correlação	MAE	Máx. Dif. Absoluta
ARVI	0.772	0.1018	2.6556
BSI	0.892	0.0392	1.8201
CDI	1.000	0.0000	0.0000
EVI	0.777	0.2679	5.6078
GNDVI	0.970	0.0386	0.4458
MNDWI	0.965	0.0478	0.6677
MSAVI	0.936	0.0540	0.6131
NBR	0.833	0.0089	0.2111
NDMI	0.833	0.0089	0.2111
NDRE	0.955	0.0282	0.3415
NDVI	0.958	0.0404	0.4680
NDWI	0.833	0.0089	0.2111
SAVI	0.958	0.0603	0.7019

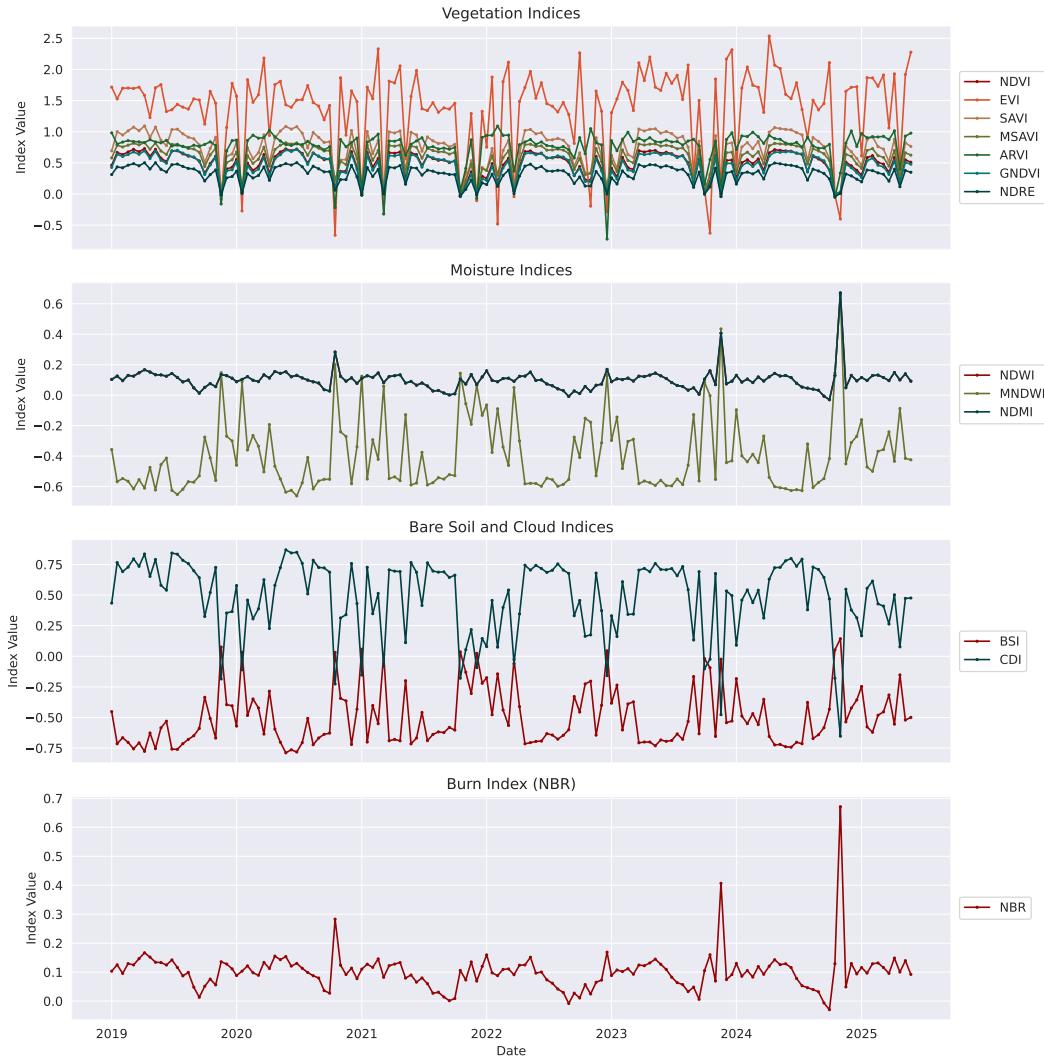


Figura 8: Séries temporais dos índices espectrais para a região de Ouro Preto (MG), sem aplicação de máscara de nuvem. Fonte: Elaborado pelo autor.

Embora o impacto médio da presença de nuvens não comprometa a análise regional agregada, conforme evidenciado pelas altas correlações e baixos erros, observa-se que os próprios índices espectrais e bandas utilizadas já apresentam robustez considerável frente a esse tipo de ruído atmosférico. Nesse sentido, a aplicação da máscara de nuvem atua mais como um refinamento metodológico do que como uma necessidade crítica para este tipo de análise média regional.

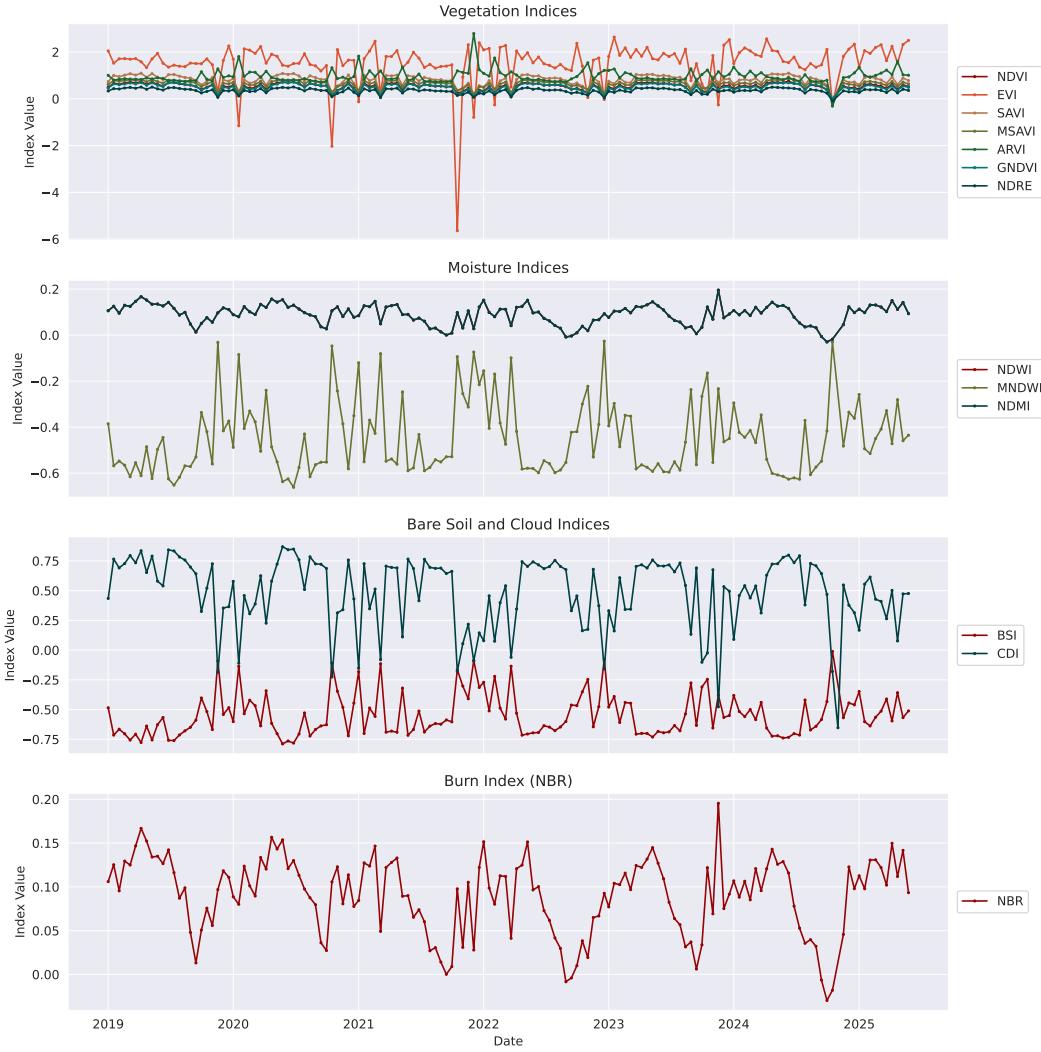


Figura 9: Séries temporais dos índices espectrais para a mesma região e período da Figura 8, com aplicação de máscara de nuvem. Fonte: Elaborado pelo autor.

4.2 Decomposição de Séries Temporais e Detecção de Rupturas

A decomposição das séries temporais permitiu isolar os componentes de tendência, sazonalidade e ruído dos índices NDVI, NDMI e NBR, como mostrado nas Figuras 10, 11 e 12. As séries revelam forte sazonalidade anual: declínio nos meses secos (junho a setembro), seguidos de recuperação com o início das chuvas (outubro a dezembro).

Apesar da presença de eventos extremos — como os incêndios registrados em agosto de 2024 — os padrões sazonais permanecem consistentes ao longo dos anos. A tendência ascendente no final de 2024, especialmente visível nos índices NDVI e NBR, sugere um processo de regeneração

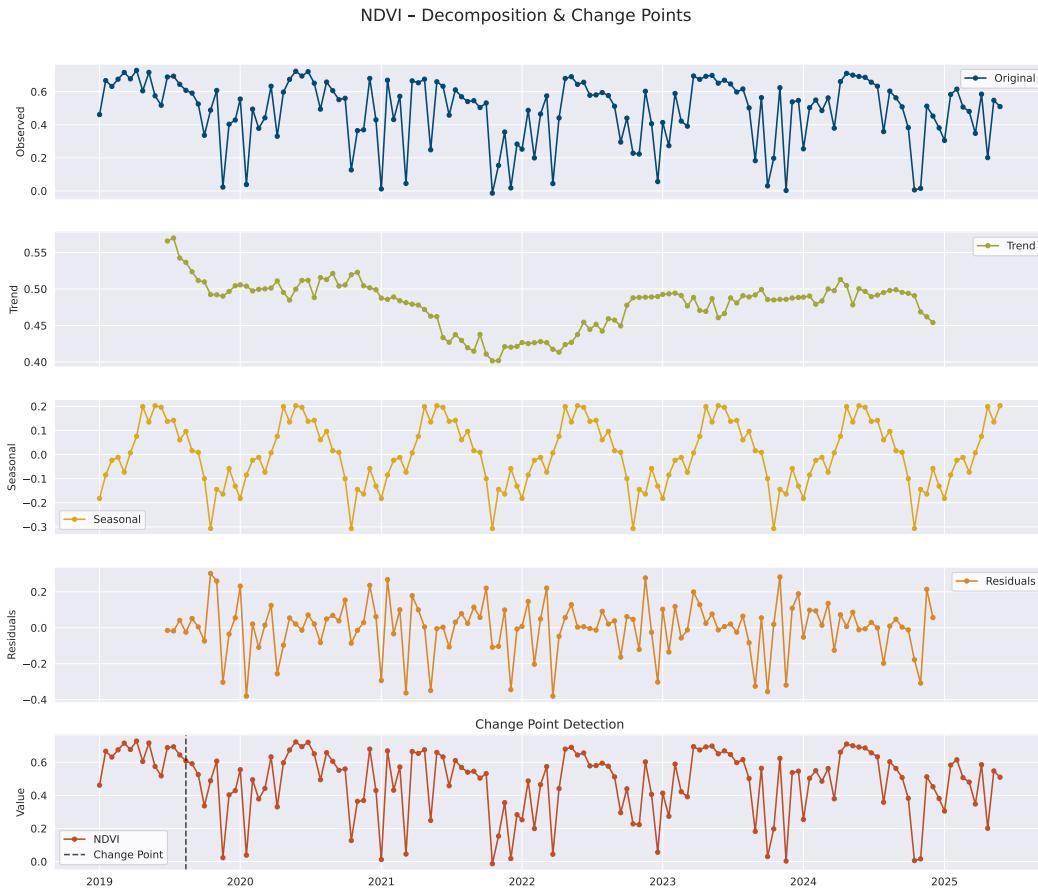


Figura 10: Decomposição da série temporal do índice NDVI para a região de Ouro Preto (MG).
Fonte: Elaborado pelo autor.

da vegetação após os eventos críticos, corroborando com os relatos de recuperação vegetal induzida pelas chuvas de primavera.

A análise de rupturas estruturais com o algoritmo PELT (modelo RBF) indicou os seguintes pontos de mudança:

- **NDVI:** 13 de agosto de 2019.
- **NDMI e NBR:** 13 de agosto de 2019, 1 de novembro de 2019, 9 de maio de 2021, 16 de outubro de 2021, 10 de junho de 2022 e 17 de novembro de 2022.

A maior quantidade de rupturas em NDMI e NBR reforça a sensibilidade desses índices a mudanças bruscas na umidade e na cobertura vegetal, especialmente ligadas a queimadas e estiagens. Por outro lado, a menor quantidade de rupturas no NDVI pode indicar maior estabilidade da

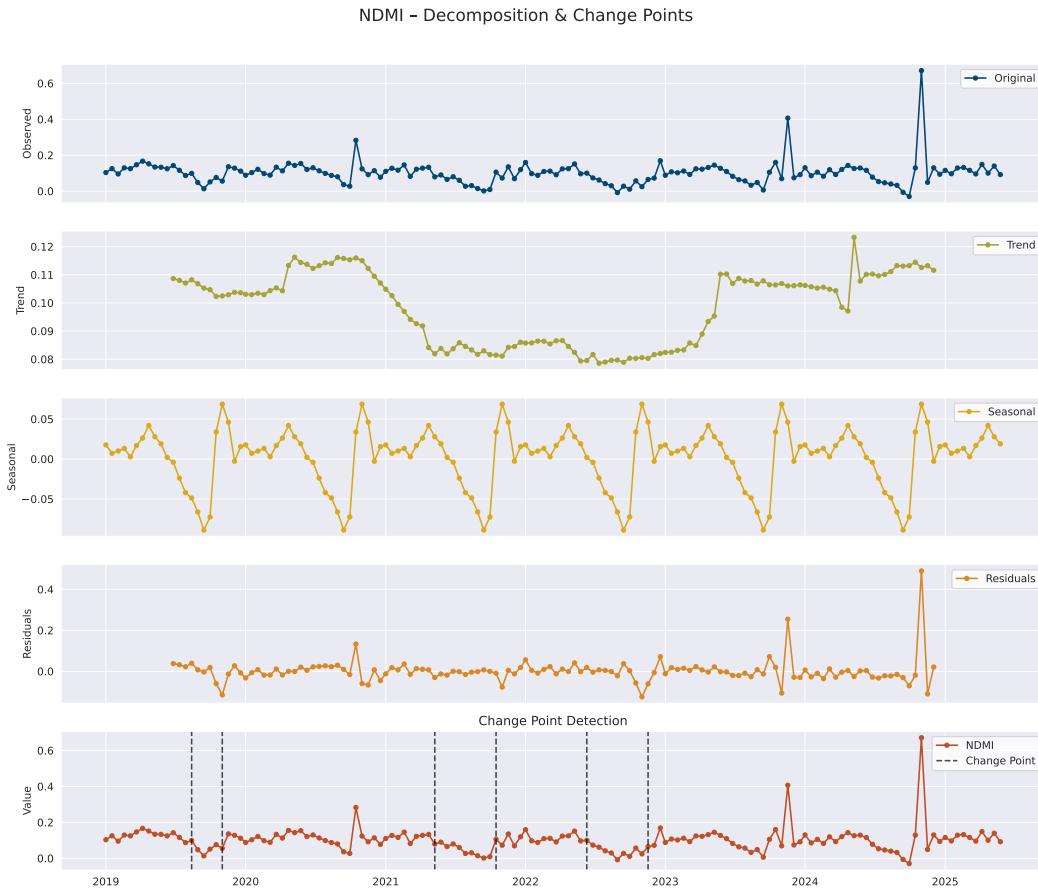


Figura 11: Decomposição da série temporal do índice NDMI, evidenciando variações sazonais associadas à umidade. Fonte: Elaborado pelo autor.

biomassa total frente a variações de menor intensidade.

Tais achados apontam para a importância de usar múltiplos índices espectrais de forma integrada, uma vez que cada métrica captura aspectos distintos do sistema ambiental. A conjugação de NDVI, NDMI e NBR se mostra particularmente útil para compreender o ciclo de degradação e recuperação vegetal típico da região, onde a seca prolongada e a ocorrência de queimadas são compensadas por chuvas vigorosas ao final do ano.

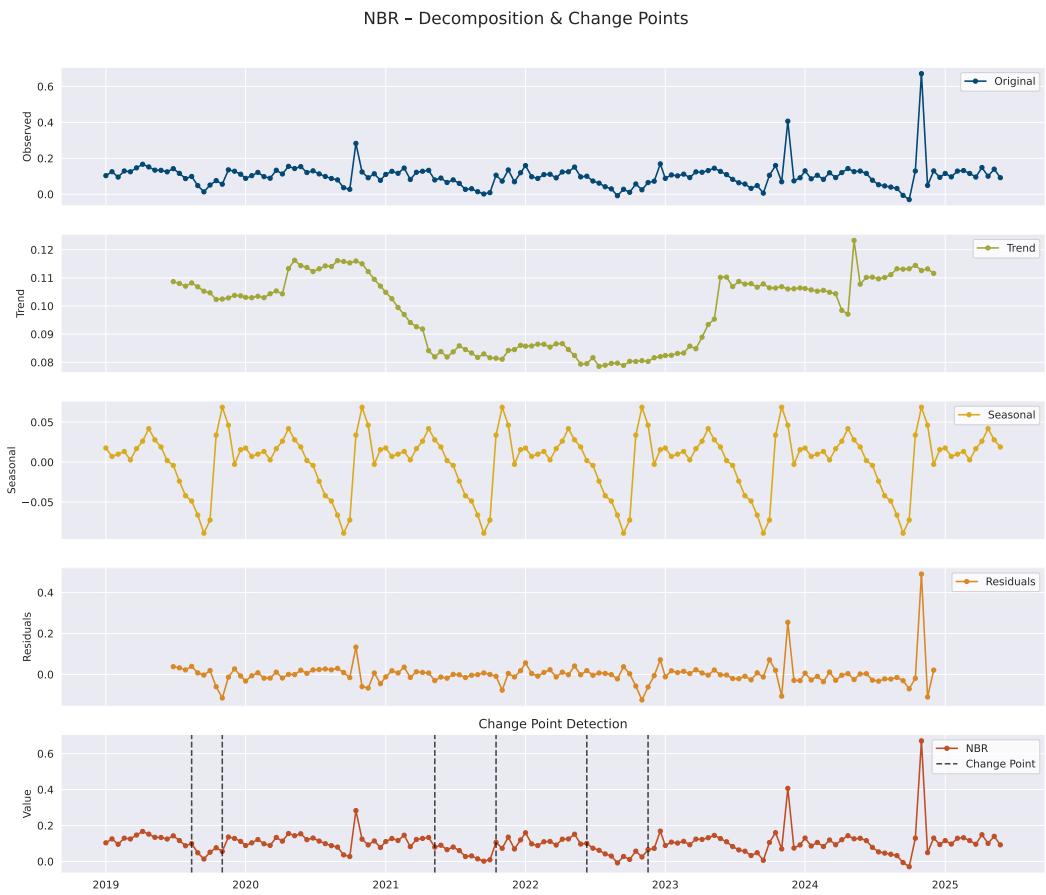


Figura 12: Decomposição da série temporal do índice NBR, destacando flutuações atribuídas a queimadas. Fonte: Elaborado pelo autor.

5 Conclusão

Este projeto demonstrou a aplicabilidade dos cubos de dados de observação da Terra — em especial, os fornecidos pelo *Brazil Data Cube* (BDC) — como ferramentas eficazes para estudos de dinâmica ambiental na região de Ouro Preto (MG). Os resultados obtidos ao longo da análise destacam importantes contribuições metodológicas e empíricas:

- A robustez e consistência dos índices espectrais derivados, mesmo frente à presença de ruídos atmosféricos como nuvens, evidenciam a confiabilidade desses indicadores para o monitoramento contínuo de vegetação, umidade e eventos ambientais críticos como queimadas;
- A aplicação de máscara de nuvem, embora recomendável como etapa de refinamento, mostrou impacto limitado sobre as médias regionais dos índices, reforçando que os próprios índices e bandas espectrais utilizados já oferecem resiliência suficiente para análises em escalas mais agregadas;
- A decomposição das séries temporais permitiu isolar padrões sazonais claros, compatíveis com o ciclo climático da região, e tendências de longo prazo, como a regeneração da vegetação após os episódios de seca e incêndios registrados em 2024;
- A detecção de rupturas estruturais em momentos específicos corrobora a sensibilidade dos índices NDMI e NBR a distúrbios ambientais, revelando sua importância para a identificação de impactos pontuais e mudanças bruscas na paisagem.

Em conjunto, esses resultados demonstram o potencial dos cubos de dados e das análises espectrais multitemporais para a caracterização de processos ecológicos e a detecção de eventos críticos em diferentes escalas temporais. O estudo reforça a importância da integração entre sensoriamento remoto, séries temporais e modelagem ambiental para subsidiar políticas públicas, estratégias de conservação e a gestão sustentável dos recursos naturais no Brasil.

Referências

(n.d.).

Banco Nacional de Desenvolvimento Econômico e Social (BNDES). (2023). *Bndes – banco nacional de desenvolvimento econômico e social*. Retrieved from <<https://www.bnDES.gov.br>> (Acesso em: jun. 2025)

Brazil Data Cube. (2025). *Brazil data cube: Plataforma para análise e visualização de grandes volumes de dados geoespaciais*. <<https://data.inpe.br/bdc/web/>>. São José dos Campos, SP, Brasil. Retrieved from <<https://data.inpe.br/bdc/web/>> (Acesso em: 13 mai. 2025)

Brazil data cube - spatiotemporal asset catalog (stac). (2023). <<https://data.inpe.br/bdc/web/stac-spatiotemporal-asset-catalog/>>. (Acesso em: 18 de junho de 2025)

Câmara, G. R., Ferreira, K., de Queiroz, G. R., Costa, K. C. S., Ferreira, L., Almeida, K. S., & de A. S. Camargo, M. (2022). *Analyzing satellite image time series with r – the sits book*. <<https://e-sensing.github.io/sitsbook/>>. (Accessed: 2025-06-18)

de Godoy, L. (2025). *Vellozia filmes*. <<https://www.velloziafilmes.com/>>. (Acesso em: 18 jun. 2025)

Fundação de Ciência, Aplicações e Tecnologia Espaciais (FUNCATE). (2023). *Funcate – fundação de ciência, aplicações e tecnologia espaciais*. Retrieved from <<https://www.funcate.org.br>> (Acesso em: jun. 2025)

Fundo Amazônia. (2023). *Fundo amazônia*. Retrieved from <<http://www.fundoamazonia.gov.br>> (Acesso em: jun. 2025)

G1 Minas Gerais. (2024). *Incêndio consome vegetação no parque do itacolomi, tradicional ponto turístico de ouro preto*. Retrieved from <<https://g1.globo.com/mg/minas-gerais/noticia/2024/08/22/incendio-consome-vegetacao-no-parque-do-itacolomi-tradicional-ponto-turistico-de-ouro-preto.ghtml>> (Acesso em: 18 jun. 2025)

Gao, B.-C. (1996). Ndwi—a normalized difference water index for remote sensing of vegetation liquid water from space. *Remote Sensing of Environment*, 58, 257–266.

Gazeta de Varginha. (2024). *Minas gerais registra agosto com mais incêndios nos últimos 13 anos, aponta inpe*. Retrieved 2025-06-18, from <<https://www.gazetadevarginha.com.br/post/minas-gerais-registra-agosto-com-mais-inc%C3%A3Andios-nos-%C3%BAltimos-13-anos-aponta-inpe>> (Acesso em: 18 jun. 2025)

Gitelson, A. A., Kaufman, Y. J., Stark, R., & Rundquist, D. (2001). Novel algorithms for remote estimation of vegetation fraction. *Remote Sensing of Environment*, 80, 76–87.

Gitelson, A. A., & Merzlyak, M. N. (1996). Signature analysis of leaf reflectance spectra: algorithm development for remote sensing of chlorophyll. *Journal of Plant Physiology*, 148, 494–500.

- Gonzalez, R. C., & Woods, R. E. (2006). *Digital image processing (3rd edition)*. USA: Prentice-Hall, Inc.
- Huete, A., Didan, K., Miura, T., Rodriguez, E., Gao, X., & Ferreira, L. (2002). Overview of the radiometric and biophysical performance of the modis vegetation indices. *Remote Sensing of Environment*, 83(1), 195–213.
- Huete, A. R. (1988). A soil-adjusted vegetation index (savi). *Remote Sensing of Environment*, 25(3), 295–309.
- Kaufman, Y. J., & Tanre, D. (1992). Atmospherically resistant vegetation index (arvi) for eos-modis. *IEEE Transactions on Geoscience and Remote Sensing*, 30(2), 261–270.
- Key, C. H., & Benson, N. C. (2006). *Landscape assessment: Ground measure of severity, the normalized burn ratio, and remote sensing of severity, the normalized burn ratio* (General Technical Report No. RMRS-GTR-164-CD). U.S. Geological Survey. Retrieved from <https://www.fs.fed.us/rm/pubs/rmrs_gtr164.html>
- Killick, R., Fearnhead, P., & Eckley, I. A. (2012). Optimal detection of changepoints with a linear computational cost. *Journal of the American Statistical Association*, 107(500), 1590–1598.
- Li, X., Zhang, Y., Liu, L., Chen, X., & Zhu, X. X. (2020). Deep learning for remote sensing image time series classification: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 162, 112–129. doi: <10.1016/j.isprsjprs.2020.02.015>
- Nielsen, A. (2019). *Practical time series analysis*. O'Reilly Media.
- Qi, J., Chehbouni, A., Huete, A., Kerr, Y., & Sorooshian, S. (1994). A modified soil adjusted vegetation index. *Remote Sensing of Environment*, 48, 119–126.
- Radar Geral. (2024). *Lobo-guará possivelmente fugindo de incêndios é visto em área urbana de ouro preto*. Retrieved from <<https://radargereral.com.br/meio-ambiente/lobo-guara-possivelmente-fugindo-de-incendios-e-visto-em-area-urbana-de-ouro-preto/>> (Acesso em: 18 jun. 2025)
- Rikimaru, A., & Miyatake, S. (2002). Development of forest canopy density map using aster and gis. In *Geoscience and remote sensing symposium* (pp. 782–784).
- Rouse, J. W., Haas, R. H., Schell, J. A., & Deering, D. W. (1974). Monitoring vegetation systems in the great plains with erts. *Third ERTS Symposium*, 1, 309–317.
- Santos, Ferreira, K. R., Picoli, M., & Camara, G. (2020). Self-organizing maps in earth observation data cubes analysis. In A. Vellido, K. Gibert, C. Angulo, & J. D. Martín Guerrero (Eds.), *Advances in self-organizing maps, learning vector quantization, clustering and data visualization* (pp. 70–79). Cham: Springer International Publishing.
- Silva, C. A., Moran, M. S., Kinoshita, R., & Anderson, M. C. (2021). Monitoring drought impacts on vegetation using satellite data: A review. *Remote Sensing*, 13(6), 1184. doi: <10.3390/rs13061184>

- Simoes, R., Câmara, G., Queiroz, G., Souza, F., Andrade, P. R., Santos, L., ... Ferreira, K. (2021). Satellite image time series analysis for big earth observation data. *Remote Sensing*, 13(13), 2428. Retrieved from <<https://doi.org/10.3390/rs13132428>> doi: <10.3390/rs13132428>
- Verbesselt, J., Hyndman, R., Newnham, G., & Culvenor, D. (2010). Detecting trend and seasonal changes in satellite image time series. *Remote Sensing of Environment*, 114(1), 106–115. doi: <10.1016/j.rse.2009.08.014>
- Wilson, E. H., & Sader, S. A. (2002). Detection of forest harvest type using multiple dates of landsat tm imagery. *Remote Sensing of Environment*, 80, 385–396.
- Xu, H. (2006). Modification of normalised difference water index (ndwi) to enhance open water features in remotely sensed imagery. *International Journal of Remote Sensing*, 27(14), 3025–3033.
- Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., & Fraundorfer, F. (2019). Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE Geoscience and Remote Sensing Magazine*, 7(4), 8–36. doi: <10.1109/MGRS.2019.2919502>
- Zhu, Z., & Woodcock, C. E. (2012). Object-based cloud and cloud shadow detection in landsat imagery. *Remote Sensing of Environment*, 118, 83–94. doi: <10.1016/j.rse.2011.10.028>
- Zhu, Z., Woodcock, C. E., Holden, C. E., & Yang, Z. (2020). Generating synthetic landsat time series by blending landsat and modis data to monitor forest disturbances. *Remote Sensing of Environment*, 248, 111984. doi: <10.1016/j.rse.2020.111984>